06 32 91 14 86

routhieretienne@gmail.com

Formation

Docteur en science des données
- **Sorbonne Université - 2021**

Master 2 en systèmes complexes
- **ENS Paris-Saclay - 2018**

Business Foundation Certificate
- **INSEAD - 2021**

Certifications

Product Manager niveau 1 & 2
- **Wiacademy**

Langues

Français **Anglais**

Etienne

Data scientist

Expérience

6

ans

Mes motivations

Data Scientist, j'associe mon expertise scientifique à une compréhension des enjeux business pour modéliser les systèmes réels et résoudre les problématiques critiques de la supply chain.

Compétences clés

Techniques :

- **Langages :** Python, Shell
- **Manipulation des données :** SQL, Pandas, Numpy, Spark, Polars
- **Machine learning :** Nixtla, Tensorflow, Sklearn, Statmodels
- **Tests :** Black, Flake8, Pytest
- **API :** FastAPI, pydantic
- **Prototype :** Streamlit
- **MLops :** MLflow
- **Cloud :** Google Cloud Plateform, Databrick
- **Orchestration :** Airflow
- **Gestion du code:** Git, GithubAction
- **Gestion de l'environnement :** Docker, Poetry

Fonctionnelles :

- **Méthodologie :** méthodes produits (Agile, Scrum, Kanban)
- **Machine learning :** Time séries, Causalité, Méthodes Probabilistes
- **Sectorielle :** Supply chain
- **IA :** méthodologie de développement (BMAD), veille et montée en compétence assistée par IA

Expériences professionnelles

Decathlon **– Data scientist (1 an 8 mois)**
Amélioration du modèle de prévision de la demande pour qu'il réponde aux facteurs externes (météo, évènements).

SSEN **– Machine Learning Engineer (4 mois)**
Déploiement et exposition d'un modèle capable d'estimer les dégâts subis par le réseau électrique lors d'une tempête.

Energys **– Data scientist (6 mois)**
Elaboration de jumeaux numériques de bâtiments pour optimiser leur gestion thermique.

Veolia **– Data scientist (10 mois)**
Création de produit de détection d'anomalie et de recommandation d'optimisation de la gestion des bâtiments

GRTgaz **– Data scientist (8 mois)**
Elaboration de modèles de prévision de la demande multi-échelle

Sorbonne Université **– Data scientist (3 ans 4 mois)**
Elaboration d'un modèle de prévision de la probabilité qu'une protéine se lie à un segment d'ADN.

Decathlon

Data scientist

20 mois

Projet :
Améliorer le modèle de prévision de la demande au service de la supply chain.

Contexte :
Decathlon a un modèle unique fondé sur des marques propriétaires et une grande intégration de la chaîne de valeur créant des enjeux forts de gestion de la chaîne d'approvisionnement. Dans ce contexte, un produit digital interne fournit au planneur les prédictions de demande chaque semaine à la maille continentale. Le produit a été amélioré en terme de précision, de sensibilité aux évènements extérieurs et d'estimation des incertitudes.

Missions :

- Développer un modèle répondant de façon causale à la météo et aux évènements extérieurs.
- Déploiement en production d'un système de mélange d'experts afin d'intégrer ce modèle avec le modèle existant.
- Veille sur les modèles de fondation (chronos 2) pour la prédiction des séries temporelles avec co-variables.
- Appui à la vision long terme du produit : gestion automatique des stocks (estimation des incertitudes) ; scénarisation avant la saison (impact du prix et du nombre de magasins sur les ventes estimées)

Environnement technique :
Databrick, Nixtla, Statmodels, Python, Pytest, Github, Pyspark

Scottish & Southern Electricity Network

Machine Learning Engineer

4 mois

Projet :
Mise en production d'un modèle prédisant les dégâts provoqués par les tempêtes sur le réseau électrique écossais.

Contexte :
SSEN est le gestionnaire du réseau électrique écossais. Dans le cadre d'une collaboration avec l'université de Glasgow un modèle de prédiction de l'impact sur le réseau électrique a été développé. Ce modèle a été mis en production et ses prédictions exposées par le biais d'une plateforme numérique. Cette plateforme est utilisée lors des réunions de gestion de crise pour anticiper les actions à prendre.

Missions :

- Conception et développement d'APIs REST avec FastAPI,
- Exposition de tables et de prédictions ML via des endpoints typés et validés avec Pydantic
- Gestion des migrations de schéma avec Alembic et SQLAlchemy
- Mise en production du modèle sur Google Cloud Composer

Environnement technique :
Alembic, FastAPI, Python, AirfFlow, GCP, Github, Pydantic, Docker

Energys

Data scientist

6 mois

Projet :
Conception d'un jumeau numérique de bâtiment pour optimiser la gestion thermique.

Contexte :
Energys est une PME de la gestion thermique des bâtiments, elle fournit les logiciels et les personnels nécessaires pour gérer les systèmes de climatisation et de chauffage. Dans l'objectif de proposer une gestion automatique et optimisée des bâtiments la réponse thermique d'un bâtiment à une commande (chauffage ou climatisation) doit être modélisée. Le projet visait à concevoir un jumeau numérique d'un bâtiment test comme première étape de R&D d'un logiciel complet.

Missions :

- Collecte, nettoyage et compréhension des données issus des capteurs de température et de fonctionnement du système de chauffage.
- Revue bibliographique des méthodes de modélisation thermique.
- Création d'un jumeau numérique du bâtiment test au moyen d'analogie électrique : state space model et optimisation bayésienne des paramètres du modèle.
- Optimisation sous contrainte des contrôles du bâtiment afin de diminuer la consommation d'énergie à confort égal.

Environnement technique :
Python, CVXPY, HiGHS, Github, Docker, R,

Veolia

Data scientist

10 mois

Projet :
Création de produit de recommandation d'optimisation de la consommation des bâtiments.

Contexte :
Veolia est un leader mondial de la gestion des ressources environnementales et effectue aussi la gestion énergétique de certains bâtiments. Dans ce cadre, Veolia groupe a souhaité développer des outils digitaux de recommandation d'optimisation de la consommation d' électricité. Ces outils permettent d'identifier les anomalies de consommation et d'estimer les gains réalisés.

Missions :

- Création d'un modèle estimant la consommation électrique d'un bâtiment avec le fonctionnement actuel.
- Création de trois modèles de détection d'anomalie de consommation énergétique.
- Conception et développement des APIs REST avec FastAPI.
- Mise en production des modèles sur Cloud Run.
- Création d'une librairie d'expérimentation en condition pré-industrielle

Environnement technique :
XGboost, FastAPI, Python, Github, Pydantic, Docker, Cloud Run, MLflow

GRTgaz

Data scientist

8 mois

Projet :
Prédiction de la consommation de gaz à plusieurs échelles.

Contexte :
GRTgaz est l'acteur majeur du transport de gaz en France, chargé de la gestion des pipelines, il a aussi pour mission l'équilibrage du réseau (mettre autant de gaz en entrée qu'en sortie). Dans ce contexte, GRTgaz fournit des prédictions de consommations aux acteurs de la distribution. Le système historique est un système de prédiction régionale désagrégé à la maille du point unitaire. La mission consistait à estimer l'intérêt d'effectuer des prédictions à la maille du point unitaire directement.

Missions :

- Estimation de la qualité des prédictions pour un ensemble de méthodes de séries temporelles à la maille des 3000 points unitaires.
- Estimation du gain apporté par un système de prédiction multi-échelle (cohérence des prédictions unitaires et agrégées).
- Estimation du coût de run et de build des solutions.
- Estimation des gains métiers et concrets apportés par les améliorations de la qualité des prédictions obtenues.

Environnement technique :
XGboost, sklearn, docker, python git

Sorbonne Université

Data scientist - doctorant

3 ans 4 mois

Projet :
Prédiction de la probabilité qu'une protéine se lie à une séquence d'ADN sur le génome.

Contexte :
Le projet GP-write est une collaboration scientifique internationale visant à concevoir à terme des génomes synthétiques fonctionnelles. Le fonctionnement des génomes dépendant en grande partie de ses interactions avec les protéines, modéliser la probabilité de liaison à partir de la séquence d'ADN est une étape nécessaire. Cette thèse a consisté à développer un algorithme de deep learning pour prédire cette probabilité de liaison puis à l'utiliser pour concevoir des séquences avec une densité souhaitée.

Missions :

- Conception et entraînement d'un réseau de neurone pour prédire la probabilité de liaison d'une protéine d'intérêt sur le génome.
- Utilisation de ce modèles pour concevoir une séquence synthétique à la densité en protéine contrôlée.
- Création d'un logiciel pour mettre en forme les données génomiques en vu de l'entraînement du réseau.
- Rédaction d'articles scientifiques.

Environnement technique :
keras, Tensorflow, bash, python git